




MoganAI

Türkçe İçin Sıfırdan
Bir Temel Model Ailesi

Sponsorluk ve İş Birliği Dosyası



1. Kısaca

MoganAI, Türkçe için sıfırdan tasarlanan ve eğitilen bir dil modeli ailesidir.

Mogan-Encoder 149M	Anlama: arama, öneri, belge eşleştirme	Eğitim sürüyor — 30 saat
Mogan-Decoder 7,5B	Üretme: yazma, özetleme, soru cevaplama	Sıradaki aşama

108B	600 GB+	7,9 puan	30 saat
token veri havuzu	ham Türkçe metin	yöntemimizin kazancı	ilk sürüme kalan

Bugüne kadarki her şey veri havuzunun toplanması, tokenizer eğitimi, mimari araştırması ve süren encoder koşusu kendi imkânlarımızla, GPU sunucularını kendi cebimizden kiralayarak yapıldı.

Modelin ötesinde bir de dağıtım tarafı var: Türkiye’de verisini yurt dışına gönderemeyen kurumlar için modeli kendi altyapılarında ve gizlilik güvencesiyle konumlandırmak, bugün yerli bir sağlayıcının bulunmadığı bir alan. Projenin ticari karşılığı burada. Encoder’ı çıkarıyoruz; decoder için hesaplama gücü ve destek arıyoruz.

2. Neden Türkçe’ye özel bir model?

Bugün kullanılan büyük modellerin hemen hepsi ağırlıklı olarak İngilizce veriyle eğitiliyor; Türkçe genellikle eğitim verisinin yüzde birinden küçük bir dilim. Bunun üç somut sonucu var.

Maliyet. Türkçe sondan eklemeli bir dil. “Görebileceklerimizden” gibi tek bir kelime, yabancı modellerin sözlüğünde beş altı parçaya bölünüyor; aynı metin İngilizcesine kıyasla kat kat fazla “token” tüketiyor. Yani her sorgu daha pahalı, daha yavaş ve modelin hafızasında daha çok yer kaplıyor. Bu, hazır bir modeli Türkçe veriyle ince ayardan geçirerek çözülebilecek bir sorun da değil sözlük eğitimin en başında sabitleniyor ve sonradan değiştirilemiyor.

Kalite. Türkçe’nin ek yapısını iyi çözemeyen bir model, kelimenin kökünü de tam yakalayamıyor; arama, sınıflandırma ve duygu analizi gibi işlerde bu fark ölçülebilir biçimde performansa yansıyor. Mevcut açık Türkçe modeller ise ya küçük ve eski mimarilere dayanıyor, ya da çok dilli modellerin Türkçe’ye artakalan kapasitesinden ibaret.

Egemenlik. Kurumsal veriyle çalışan şirketler ve kamu kurumları için veriyi yurt dışındaki bir API’ye göndermek çoğu zaman ya mevzuat açısından sorunlu ya da tamamen imkânsız. Kendi sunucusunda çalışabilen, Türkçe öncelikli bir model bu boşluğu dolduruyor.

3. Neden önce encoder, sonra decoder?

Encoder ucuz, decoder pahalı. Encoder eğitimi birkaç günlük bir koşuyla tamamlanabiliyor; 7,5 milyar parametrelilik bir decoder bunun onlarca katı hesaplama gücü istiyor.

Yatırımın büyük kısmı ortak. Veri havuzu, temizleme hattı, tokenizer ve eğitim altyapısı iki model için de aynı. Encoder’ı çıkarırken bu altyapının tamamını kurmuş ve gerçek bir koşuda sınanmış oluyoruz yani decoder koşusunda çok pahalıya patlayacak hataları önceden yakalıyoruz.

Encoder tek başına da bir ürün. Arama, öneri ve belge eşleştirme kurumların her gün kullandığı işler; model küçük olduğu için ucuza, hatta CPU üzerinde bile çalışabiliyor.

4. Nereye geldik

4.1 Veri toplama

Türkçe, internetteki metin hacmi açısından İngilizce'nin çok gerisinde; bu ölçekte temiz bir havuz oluşturmak projenin en uzun süren aşamasıydı ve hazır indirilebilecek bir kaynak yok.

Havuz kamu arşivleri, akademik yayınlar, haber ve süreli yayınlar, forum içeriği, teknik dokümantasyon ve koddan derlendi. Her kaynak ayrı değerlendirilip lisans durumu belgelendi, sonra ortak bir işleme hattından geçirildi: yinelenen içerik ayıklama, kalite filtreleme, biçim normalizasyonu ve eğitime hazır paketleme. Bu havuz hem encoder hem decoder için ortak temel bir kez ödenen, iki kez kullanılan bir yatırım.

4.2 Tokenizer

Tokenizer, modelin metni parçalara ayırma biçimi; model daha bir şey öğrenmeden önce alınan ve sonradan değiştirilemeyen bir karar. Yukarıdaki maliyet sorununun kaynağı doğrudan burası. Türkçe'ye özel, 50 bin parçalık kendi tokenizer'ımızı eğittik ve mevcut Türkçe alternatiflerle sistematik olarak karşılaştırdık: bir cümlemin kaç parçaya bölündüğü, bölünme noktalarının Türkçe'nin gerçek ek yapısıyla örtüşüp örtüşmediği ve bunların model performansına yansımaları. Sonuç, Türkçe metni rakiplerinden daha az parçaya bölen bir sözlük her sorguda daha düşük maliyet, daha yüksek hız.

4.3 Araştırma ve encoder tasarımı

Mimariyi seçerken literatürü takip etmekle yetinmedik, kendi hipotezimizi kurup test ettik. Anlama modelleri klasik olarak tek bir yöntemle eğitilir: metnin bir kısmı gizlenir, model gizlenen kısmı tahmin eder. Bizim önerimiz, eğitimin ilk çeyreğinde modele önce **metni baştan sona yazmayı** öğretmek, kalanında klasik anlama eğitimine geçmek.

Model, anlamayı öğrenmeden önce dilin akışını öğreniyor. Kontrollü bir deneyde bunun karşılığı, Türkçe arama doğruluğunda **7,9 puanlık** artış oldu.

Projenin özgün bilimsel katkısı ve yayına dönüşecek kısmı bu. Modeli tek bir sayıya bakarak da değerlendirmiyoruz: arama isabeti, dilbilgisel yapı testleri ve temsil sağlığı diagnostikleri olmak üzere üç ayrı ölçüm hattı kurduk.

4.4 Ana encoder koşusu

Model	149 milyon parametre, modern encoder mimarisi
Donanım	4 × H100 GPU, bulut üzerinden spot kiralık
Durum	Eğitim sürüyor — ilk sürüm 30 saat içinde

Bu koşunun sunucu maliyetini kendi cebimizden karşılıyoruz ve bütçe nedeniyle **spot sunucu** kullanmak zorundayız: normal fiyatın ciddi biçimde altında, ama sağlayıcı tarafından her an kesilebilen makineler. Eğitim hiçbir uyarı olmadan durabildiği için altyapıyı en baştan kesintiye dayanıklı kurmak koşunun kaldığı yerden, hiç ilerleme kaybetmeden devam edebilmesini sağlamak zorunda kaldık. Aynı sebeple donanım verimliliği üzerinde ayrıca çalıştık: aynı GPU'lardan aldığımız faydayı iki katından fazlasına çıkardık.

Bu, verilen hesaplama gücünün israf edilmediğinin kanıtı; aynı zamanda projenin şu anda gereksiz yere yavaş ilerlemesinin sebebi.



5. Sıradaki adım: Decoder

Hedef: 7,5 milyar parametrelilik, Türkçe öncelikli üretim modeli yeterince büyük ki gerçek işlerde kullanılabilsin, yeterince küçük ki tek bir kurumsal sunucuda çalıştırılabilsin.

Decoder sıfırdan başlamıyor: veri havuzunun tamamı, tokenizer, temizleme hattı, eğitim altyapısı ve bir tur gerçek koşu tecrübesi encoder'dan devrediyor. Kendi imkânlarımızla aşamadığımız tek eşik, gereken hesaplama gücü.

Donanım	8 × H100
Süre	~60 gün kesintisiz
Toplam	~11.500 GPU saati

6. Dağıtım: Türkiye'de kapatılmamış bir boşluk

Modeli eğitmek için yarısı; asıl değer nasıl dağıtıldığında ortaya çıkıyor. Türkiye'de bankacılık, sağlık, hukuk, sigorta ve kamu tarafında yapay zekâya ihtiyacı olan ama verisini yurt dışındaki bir servise gönderemeyen çok sayıda kurum var; bugünkü seçenekleri ya mevzuata rağmen yurt dışı servis kullanmak, ya da açık modellerle kendi başlarına uğraşmak.

Elimizde Türkçe'de iyi çalışan bir model olduğunda bu boşluğa doğrudan oturan bir dağıtım modeli mümkün: **kuruma özel, kurumun kendi altyapısında çalışan, verinin hiçbir aşamada dışarı çıkmadığı bir kurulum**. Model ağırlıkları yerinde, çıkarım yerinde, gizlilik sözleşmeyle güvence altında.

Bir kez eğitilen model, birden fazla kuruma ayrı ayrı konumlandırılabilir ve bu tarafta Türkçe'ye özel, yerli bir sağlayıcı henüz yok.

7. Sponsorluk

Hesaplama gücü. Projenin baskın maliyeti bu. GPU saati, bulut kredisi veya doğrudan donanım erişimi hangi biçimde olursa olsun tamamı decoder eğitimine gidiyor. Spot sunucu kısıtından kurtulmak tek başına ciddi bir hız kazancı demek.

Finansman. Veri işleme, depolama, değerlendirme koşulları ve ekibin bu işe ayırdığı zaman.

Destek, klasik anlamda bir sponsorluk ilişkisi olarak kurgulanabileceği gibi ortaklık biçiminde de yapılandırılabilir; dağıtım modelinin ticari bir karşılığı var ve karşı taraftan böyle bir teklif gelmesine açığız. Koşulları muhatabımıza göre birlikte belirlemeyi tercih ediyoruz, peşinen çizilmiş bir paket sunmuyoruz.

MoganAI

Hugging Face : <https://huggingface.co/moganai>